專業摘要（約 500 字）

本研究旨在建立一套以台灣環境部逐時空氣品質資料為基礎的 **Tool-augmented Evidence Agent**，以解決生成式大型語言模型（LLM）在空氣品質問答中常見的數值幻覺、資料錯配與來源不可追溯問題。空氣污染為全球首要環境健康風險因子，WHO 估計每年造成約 660 萬人死亡，且全球約 99% 人口暴露於超過 WHO PM2.5 年均 guideline 的濃度；因此，建立即時、可信且可追溯的空品資訊系統，具有明確的公共衛生與政策價值。

現行環境部已開放 AQX_P_488 逐時 AQI 歷史資料，涵蓋測站、AQI、PM2.5、PM10、O3、SO2、CO、NO2、風速、風向、經緯度及資料建立時間等欄位。然而，使用者仍須自行處理測站對齊、時間戳記、污染物單位、移動平均值、AQI 等級判定及資料缺漏等問題；若直接交由生成式 LLM 回答，容易產生站點、時間或數值錯配。此外，既有研究顯示，即使採用 RAG，LLM 仍可能產生事實或數值幻覺，且既有空品 Agent 如 Neuro-Air，並未針對台灣站級逐時資料、台灣 AQI 規則、資料衝突偵測及可拒答機制進行在地化設計。

本研究提出將語言理解、資料檢索、數值計算與規則判定明確分工的架構：LLM 負責理解使用者意圖、組織證據與生成說明；確定性工具負責查詢、對齊、計算、比較與規則判定。系統以 (SiteId, DataCreationDate) 作為唯一觀測鍵值，避免同名測站、行政區混淆或跨小時、跨更新批次的數值錯配。當資料不足、時間範圍不支援、測站不存在或出現數值衝突時，系統將採取證據連結的拒答機制，而非讓 LLM 自行推測。

實驗將建立 60 題台灣在地空品測試集，包含 45 題可回答題與 15 題資料不足、衝突或拒答題，並比較 LLM-only、Deterministic Tools Only 及本 Agent 三種模式。評估指標包括回答正確率、數值正確率、AQI 等級判定正確率、來源引用正確率、拒答正確率及資料衝突偵測率。現階段已完成 2026/1/1 至 10/29 共 970,296 筆原始資料清理，保留 606,137 筆獨立觀測，並隔離 13 組數值衝突。本研究預期能在維持可用性的同時，提升數值正確性、來源可追溯性與拒答可靠性，為台灣空品資訊系統提供可驗證、可解釋且可重現的 AI 決策支援基礎。